

Soft Spaces Phase 4

v41.0 - DLBCL Benchmark Application

Arbejdsbeskrivelse for bioinformatisk benchmark: GCB vs ABC

Formål: At teste om Soft Spaces-formalismen kan genfinde og prioritere kendt DLBCL cell-of-origin struktur bedre end stringent NULL-kontrol og konkurrencedygtigt i forhold til klassiske data-science baselines.

1. Executive summary

v41.0 flytter Soft Spaces fra den abstrakte/hardware-validerede Phase-4 ramme til en konkret bioinformatisk anvendelse. Benchmark-problemet er DLBCL cell-of-origin (COO): germinal-center B-cell-like (GCB) versus activated B-cell-like (ABC). Dette er et veletableret genekspressionsproblem, som gennem mange år er blevet analyseret med klassisk statistik, clustering, feature selection og supervised machine learning.

Den primære idé er ikke at erstatte bioinformatik med kvantemekanik, men at genbruge Soft Spaces-formalismen - subspaces, REAL/NULL, prominence og strukturbaseret ranking - på et højdimensionelt biologisk datasæt. Første udvikling og benchmark udføres lokalt. IBM Heron anvendes kun senere som en eventuel afsluttende hardwarekontrol af et allerede fastlåst signal.

2. Hvorfor netop GCB vs ABC?

DLBCL er biologisk heterogen. Gene-expression profiling har etableret COO-undergrupperne GCB, ABC og en unclassified gruppe. Det gør GCB-vs-ABC til et attraktivt benchmark: der findes kendt biologisk struktur, etablerede labels, historiske datasæt og et stort sammenligningsgrundlag fra klassiske metoder.

Primært datasæt	GSE10846 - Affymetrix Human Genome U133 Plus 2.0; 420 DLBCL-prøver i GEO.
Ekstern validering	GSE31312 - 498 de novo DLBCL-prøver; GCB, ABC og unclassified beskrevet via global genekspressionsprofilering.
Primær opgave	Binær klassifikation og feature-ranking: GCB versus ABC.
Hvorfor egnet	Velkendt biologisk struktur, stort historisk benchmarkgrundlag og offentligt tilgængelige data.

3. Præcise forskningsspørgsmål

- RQ1: Kan Soft Spaces genfinde en stabil REAL-struktur i DLBCL-genekspressionsdata, som ikke optræder i en matchet NULL-kontrol?
- RQ2: Kan Soft Spaces rangere COO-relevante features eller feature-subspaces tidligere/højere end NULL?
- RQ3: Er Soft Spaces-kvaliteten konkurrencedygtig med standardmetoder som logistisk regression, SVM, Random Forest og PCA+classifier?
- RQ4: Overlever den fundne struktur ekstern validering fra GSE10846 til GSE31312?
- RQ5: Hvis signalet er robust lokalt, kan en reduceret version senere bekræftes på kvantehardware uden at ændre den biologiske konklusion?

4. Data og preprocessing

Første iteration bør være konservativ og reproducerbar. Ingen feature-engineering må baseres på testlabels efter datasplit.

Trin	Handling	Kontrol
1	Download GSE10846 expression matrix og sample metadata.	Gem rå accession, platform og download-dato.
2	Identificér COO-labels og behold først GCB og ABC.	Unclassified holdes ude af første binære benchmark.
3	Map probes -> gener med dokumenteret, reproducerbar regel.	Reglen fastlåses før modelkørsel.
4	Log2/normalisering kun hvis nødvendigt ud fra den leverede matrix.	Undgå dobbelt-normalisering.
5	Train/test-split eller nested CV stratificeret efter COO.	Ingen lækage fra test til feature selection.
6	Standardisering beregnes på training fold og anvendes på test fold.	Pipeline-objekt eller eksplicit fold-sikker kode.
7	GSE31312 røres ikke før v41.0-modellen er låst.	Bruges som ekstern validering, ikke som tuning-data.

5. Hvordan Soft Spaces oversættes til bioinformatik

Den centrale metodeidé er at bevare formalismen, men ændre hvad objekterne repræsenterer. I Phase 3 var objekterne tilstande/subspaces i et Hilbert-rum. I v41.0 repræsenterer de biologiske features eller reducerede feature-kombinationer.

Soft Spaces-begreb	v41.0 fortolkning	Kommentar
REAL	Den observerede GCB/ABC-relaterede struktur i træningsdata.	Biologisk struktur bevares.
NULL	Label- eller strukturpermutation, der bevarer marginale dataegenskaber men bryder COO-relationen.	NULL skal være stringent og matchet.
Subspace	Et delrum af features eller en reduceret latent repræsentation.	Dimensionen skal være lav nok til stabil beregning.
Prominence	Soft Spaces-score for hvor tydeligt et kandidat-subspace skiller sig ud.	Anvendes til ranking.
Ranked search	Prioritering af features/subspaces efter prominence.	Sammenlignes direkte med standard feature-ranking.
Target	Kendt COO-relevant biologisk signal eller korrekt klassifikationsmål.	Definition fastlåses før evaluering.

6. NULL-design - afgørende for et troværdigt resultat

NULL må ikke være en trivial nulvektor. Den skal bevare så meget af datasættets almindelige struktur som muligt, mens den specifikke COO-association brydes. Førstevalg bør være label permutation inden for træningsfolds. Sekundære NULL-varianter kan senere omfatte feature-wise permutation eller matched random subspaces.

- Primary NULL: permuter GCB/ABC-labels inden for hver træningsfold.
- Secondary NULL A: permuter hver feature på tværs af samples for at bryde korrelationer.
- Secondary NULL B: matched random feature sets med samme størrelse som REAL-selected sets.
- Alle permutationer styres af faste seeds og genbruges på tværs af modeller.

7. Baselines - hvad Soft Spaces skal konkurrere imod

For et retvisende benchmark skal Soft Spaces ikke sammenlignes med en svag straw-man, men med solide standardmetoder.

Baseline	Formål	Vigtig metric
Univariate ranking	Ranger gener enkeltvis efter fx t-statistik/ANOVA-lignende score.	Feature recovery / Precision@K
Logistic Regression + regularization	Lineær supervised reference.	ROC-AUC, balanced accuracy
Linear/RBF SVM	Klassisk højdimensionel classifier.	ROC-AUC, balanced accuracy
Random Forest	Ikke-lineær ensemble-reference.	ROC-AUC, feature importance
PCA + Logistic/SVM	Lavdimensionel standardreference.	ROC-AUC, dimensionality vs performance
Optional XGBoost	Stærk moderne tree baseline, sekundært.	ROC-AUC / calibration

8. Endpoints og beslutningskriterier

Primary classification	ROC-AUC på hold-out/nested-CV og senere ekstern GSE31312.
Primary ranking	Precision@K for et prædefineret biologisk target-set.
Secondary ranking	NDCG@K og evaluations-to-target / evaluations saved.
Robusthed	Bootstrap CI og seed-wise REAL-NULL forskelle.
Generalisation	Samme låste pipeline på GSE31312 uden retuning.

Et vigtigt princip er, at v41.0 ikke skal erklæres succesfuld blot fordi Soft Spaces kan klassificere GCB/ABC. Den interessante påstand er stærkere: strukturbaseret ranking skal give en robust fordel over NULL og samtidig være konkurrencedygtig med etablerede baselines på samme datasplit.

9. Arbejdspakker og versionsplan

Version	Arbejdspakke	Output	Stop/go
v41.0	Data acquisition + metadata audit	Reproducerbart GSE10846 input + label table	GO hvis labels og matrix kan kobles entydigt
v41.1	Preprocessing + leakage-safe folds	Frozen preprocessing manifest	GO hvis folds og QC er stabile
v41.2	Classical baselines	Baseline metrics + CV distributions	Fastlæg reference før Soft Spaces
v41.3	Soft Spaces REAL/NULL mapping	Prominence/ranking per seed/fold	GO hvis REAL-NULL signal er stabilt
v41.4	Head-to-head benchmark	Soft Spaces vs baselines	Ingen cherry-picking
v41.5	External validation on GSE31312	Locked external result	Primær generalisationstest
v41.6	Optional Aer translation	Circuit-level reduced benchmark	Kun hvis klassisk signal er stærkt
v41.7	Optional Heron confirmation	Minimal QPU hardware check	Kun efter runtime-budget preflight

10. Hvad testen kan og ikke kan vise

Kan vise: om Soft Spaces kan genfinde, prioritere og generalisere kendt DLBCL COO-struktur i offentlige genekspressionsdata, og om denne ranking giver en reproducerbar fordel over NULL og standardbaselines.

Kan ikke vise: klinisk nytte for en individuel patient, behandlingsrespons, prognose for en konkret person eller at Soft Spaces erstatter etableret diagnostik. Dette er et metode- og benchmarkstudie, ikke et klinisk beslutningsværktøj.

11. Forslag til predeclared success criteria

- S1: REAL - NULL ranking delta > 0 i gennemsnit over alle låste folds/seeds.
- S2: Bootstrap 95% CI for den primære REAL-NULL ranking-delta har nedre grænse > 0.
- S3: Ekstern validering på GSE31312 bevarer retningen uden retuning.
- S4: Soft Spaces ligger inden for en på forhånd fastlagt margin af den bedste klassiske classifier på ROC-AUC, eller giver en klar ranking/evaluation-effektivitet som de klassiske modeller ikke giver.
- S5: Alle preprocessing-, target- og NULL-regler er fastlåst før ekstern validering.

12. Første konkrete næste skridt

Start v41.0 med én opgave: hent GSE10846, byg en audit-tabel over samples og identificér de eksakte GCB/ABC labels. Ingen Soft Spaces-beregning før datagrundlaget er verificeret.

Når datasættet er verificeret, oprettes en frozen data manifest-fil med accession, sample-ID, COO-label, platform, preprocessing-status, eksklusionsregel og checksums. Derefter kan v41.1 begynde.

13. Kilder

1. NCBI GEO GSE10846: "Prediction of survival in diffuse large B cell lymphoma treated with chemotherapy plus Rituximab". 420 samples; Affymetrix HG-U133 Plus 2.0.
<https://www.ncbi.nlm.nih.gov/geo/query/acc.cgi?acc=GSE10846>
2. NCBI GEO GSE31312: 498 de novo adult DLBCL cases; global gene expression profiling identifying GCB, ABC and unclassified groups. <https://www.ncbi.nlm.nih.gov/geo/query/acc.cgi?acc=GSE31312>
3. Lenz G et al. Stromal Gene Signatures in Large-B-Cell Lymphomas. N Engl J Med. 2008;359:2313-2323. DOI: 10.1056/NEJMoa0802885.
4. Schmitz R et al. Genetics and Pathogenesis of Diffuse Large B-Cell Lymphoma. N Engl J Med. 2018;378:1396-1407. DOI: 10.1056/NEJMoa1801445.